

Redes Neurais & Deep Learning

Entendendo da teoria à prática!

Leonardo Mauro P. Moraes

Agenda


Redes Neurais & Deep Learning

- Conceitos de Redes Neurais
- Perceptron
- Multilayer Perceptron
- Deep Learning
 - O que é?
 - Tipos de Rede e Nós
- Discussão

Paradigma – Conexionista


Conexionista

- Baseado na metáfora biológica com as conexões neurais do sistema nervoso.
 - Diretamente ligado às Redes Neurais.
- Envolve unidades altamente interconectadas.
- São exemplo,
 - Perceptron,
 - Multilayer Perceptron, e
 - Deep Learning.



[Assessment Of Artificial Neural Network For Bathymetry Estimation Using High Resolution Satellite Imagery In Shallow Lakes: Case Study El Burullus Lake.](#)

Neurônio Natural




Neurônio simplificado

- Neurônio
- Dendritos
- Axônios
- Sinapse

Fonte: [André Ponce de Leon F de Carvalho](#)

Neurônio Artificial



Neurônio artificial

- Neurônio - $f(x)$
- Dendritos - *Entradas*
- Axônios - *Saída*
- Sinapse - *Sinal*

Fonte: [André Ponce de Leon F de Carvalho](#)

Perceptron – Introdução

Perceptron

- Implementado - Rosemblat (1958);
- Proposto - McCulloch-Pitts (1943).

Tarefas


- Classificação; Regressão.

Funcionamento

- Valores, pesos, e saída;
- Correção de erro.

$$f(x) = y = (x_1 * w_1) + (x_2 * w_2) + (x_3 * w_3) \quad \left\{ \begin{array}{l} 1, \text{ se } f(x) > 0 \\ 0, \text{ caso contrário.} \end{array} \right.$$

(Classificação)



Perceptron Model (Minsky-Papert in 1969)

[What is a perceptron?](#)

Perceptron – Aprendizado

Correção de Erro

Inicializa os pesos aleatoriamente;

Para cada época;


- Se eu acertei a predição, ok;
- Se não, altera os pesos.
 - $w_i = w_i + \Delta w_i$
 - $\Delta w_i = \eta(t - o)x_i$

Resumidamente

- “Se faltou, ele sobe o valor”; e
- “Se sobrou, ele desce o valor”.

$$f(x) = y = (x_1 * w_1) + (x_2 * w_2) + (x_3 * w_3) \begin{cases} 1, \text{ se } f(x) > 0 \\ 0, \text{ caso contrário.} \end{cases}$$

(Classificação)



Perceptron Model (Minsky-Papert in 1969)

[What is a perceptron?](#)

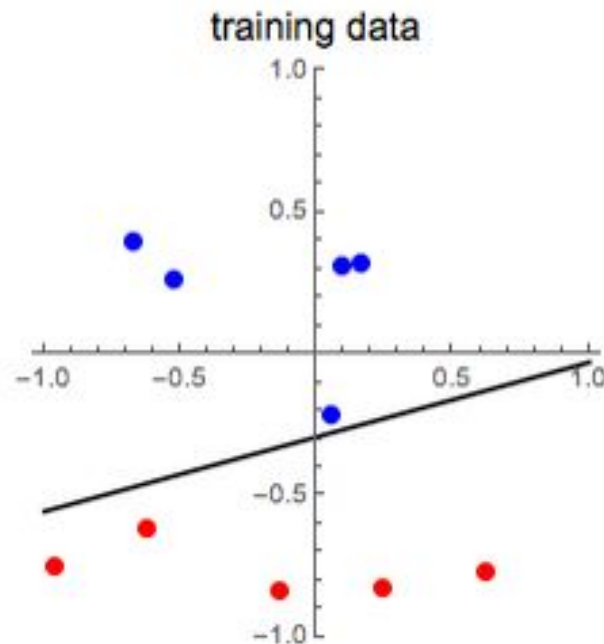
Perceptron – Teoria

Treinamento Supervisionado

- Aprende uma função linear.
- Teorema de convergência
 - Se os dados forem linearmente separáveis, então o algoritmo do perceptron irá corrigir para um conjunto consistente de pesos.

Notas

- Não aprende funções complexas.
- Minsky e Papert (1969) escreveram um livro analisando o perceptron e descrevendo funções que ele não podia aprender.



Multilayer Perceptron – Introdução

Multilayer Perceptron


- Popularizou em 1980s;
- **Aplicações** - Speech Recognition; Image Recognition; e Machine Translation.

Tarefas

- Supervisionado; e Não supervisionado.

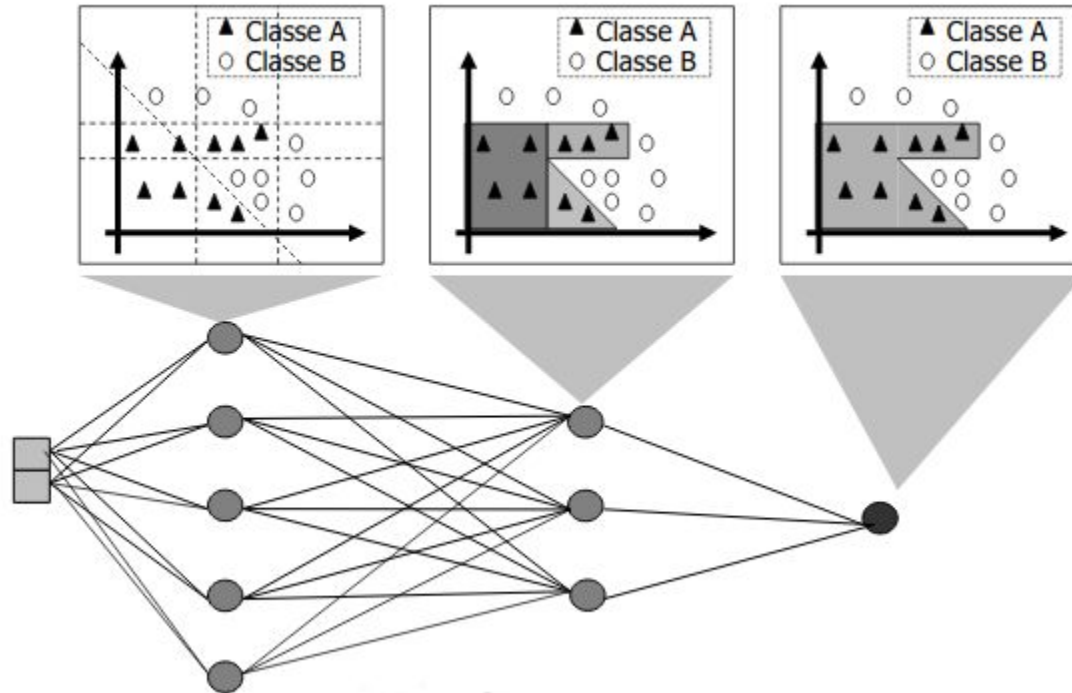
Arquitetura

- Camada de entrada; escondida; e saída;
- Totalmente conectada;
- Função de ativação: relu, sigmoid, log...



[How to Train a Multilayer Perceptron Neural Network](#)


Multilayer Perceptron – Exemplo



Multilayer Perceptron – Funcionamento



...and we have a **green squiggle** that fits the data.




Funcionamento

- Valores, pesos, **viés (bias)**;
- Função de ativação;
- Backpropagation - Aprendizado.
 - Bias e pesos.
 - *por meio do SRR (resíduos); e*
 - *usando Gradient Descendent.*

Arquitetura

- Ativação:
 - relu,
 - sigmoid,
 - natural log




Multilayer Perceptron – Teoria

Treinamento Supervisionado

- Forward (sinal); e backward (erro).

Teoria

- Representa funções não lineares.
- Duas camadas escondida:
Representa qualquer função
 - Lippmann (1987) "[An introduction to computing with neural nets](#)".
- Uma camada escondida
 - Allan Pinkus (1999) "[Approximation theory of the MLP model in neural networks](#)"




[How to Train a Multilayer Perceptron Neural Network](#)

Multilayer Perceptron – Notas

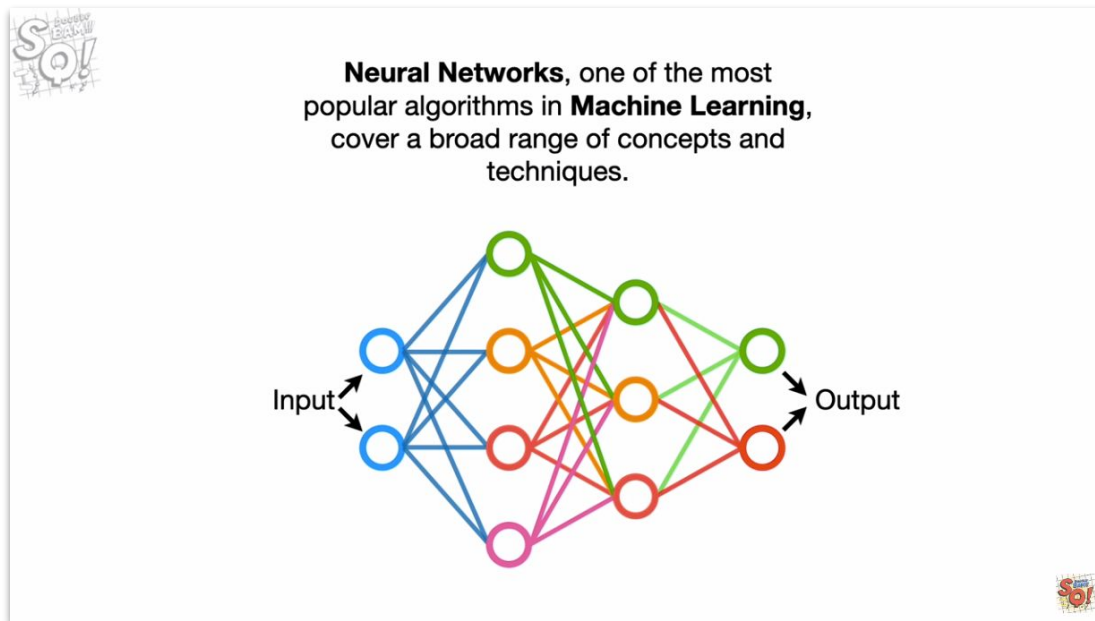
Notas

- Usualmente, possuem 1 ou 2 camadas escondidas.
- Quantas camadas escondidas ou nós por camada?
 - *“Use systematic experimentation to discover what works best for your specific dataset.”*
- [Deep Learning](#) (2016)
- Muitas teorias, mas nenhuma tem certeza.
- Treinamento lento, relação ao número de nós.
- Não é interpretável - não dá para entender a caixa preta.
- É “semi” incremental - aprende com novos exemplos.
 - *“Online learning”*



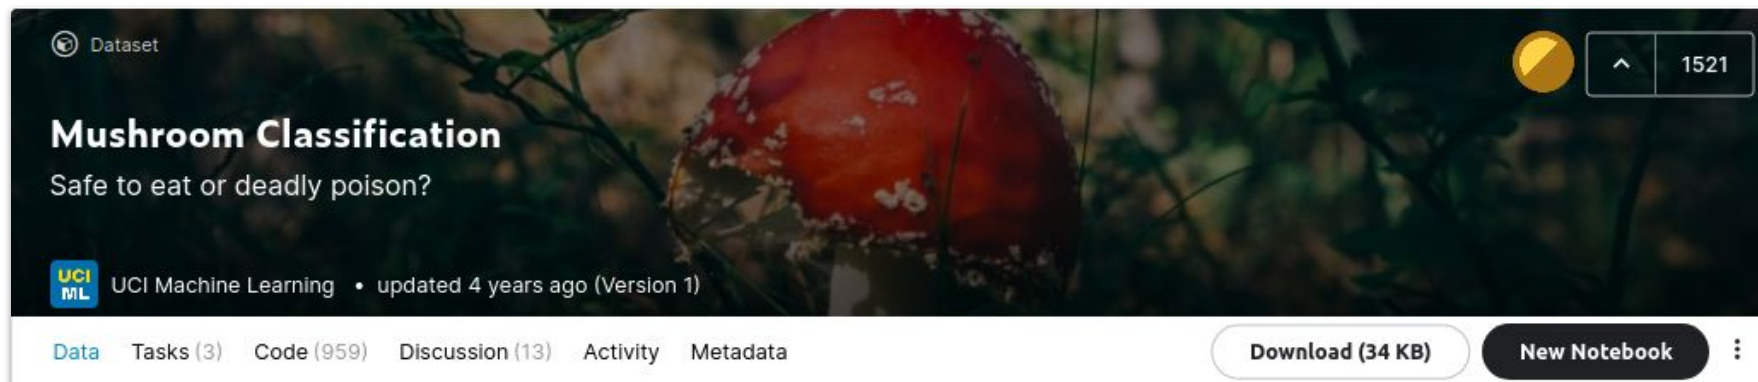
fonte desconhecida

Multilayer Perceptron – Complemento



StatQuest - Neural Networks: Inside the Black Box [[pt.1](#), [pt.2](#), [pt.3](#), [pt.4](#)]

Redes Neurais – Classificação



Dataset

Mushroom Classification

Safe to eat or deadly poison?

UCI Machine Learning • updated 4 years ago (Version 1)

Data Tasks (3) Code (959) Discussion (13) Activity Metadata

Download (34 KB) New Notebook

1521

<https://www.kaggle.com/leomauro/redes-neurais-classifica-o-de-cogumelos>

Deep Learning – O que é?

Aprendizado Profundo (*Deep Learning*) (~2010)

“Empirically, greater depth does seem to result in better generalization for a wide variety of tasks. [...] This suggests that using deep architectures does indeed express a useful prior over the space of functions the model learns.”

[Deep Learning](#) (2016)

Resumidamente

- Redes Profundas são muitas camadas escondidas.
- Testar diferentes arquiteturas para diferentes tarefas.
- Boom - neurônios com funcionalidades específicas



Giphy - [Blow Your Mind](#)


Deep Learning – O que é?

Multilayer Perceptron - Redes Rasas

- Características extraídas manualmente (por especialistas) ou por técnicas de extração de dados.
- Poucas camadas que tornam difícil extrair função que represente os dados.


Deep Learning - Redes Profundas

- Características extraídas hierarquicamente por algoritmos de aprendizado automaticamente.
 - “ele descobre sozinho”.
- Características não interpretáveis.




Deep Learning – O que é?

1980S-ERA NEURAL NETWORK




DEEP LEARNING NEURAL NETWORK





[News Feature: What are the limits of deep learning?](#)


Deep Learning – O que é?



Layer 1

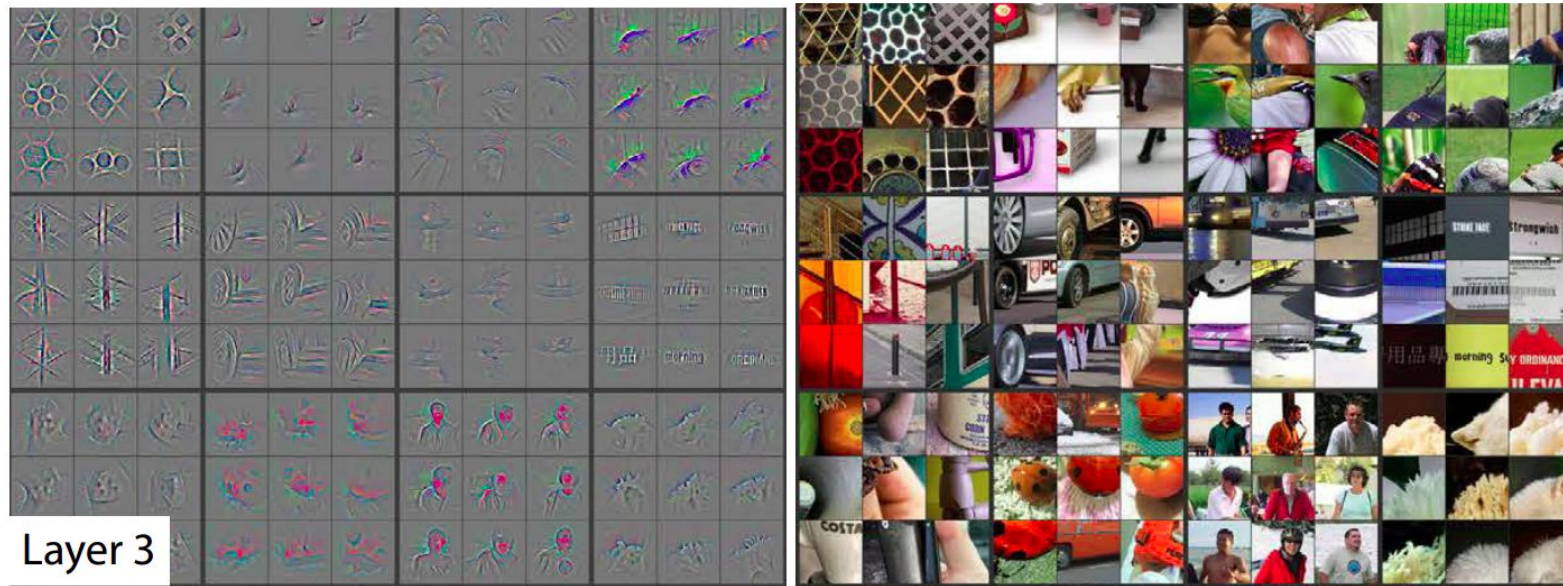


Layer 2




[Visualizing and Understanding Convolutional Networks \(2014\)](#)

Deep Learning – O que é?



[Visualizing and Understanding Convolutional Networks \(2014\)](#)

Deep Learning – O que é?



O que vocês acham que é a imagem ao lado?

- Acertou quem disse um som.
- Som ao longo do tempo.

Interessante é que...

- Aprende imagens
- Aprende sons, infravermelho
- Aprende textos

Qualquer coisa que você transformar num vetor.

Deep Learning – Aplicações

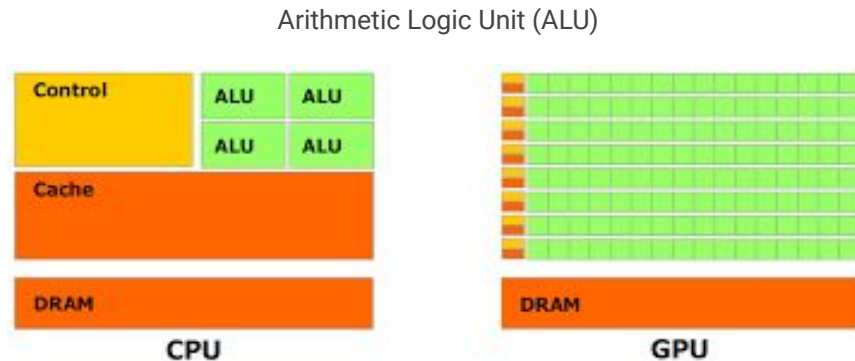
- **Natural Language Processing (NLP)** - Answering questions; speech recognition; summarizing documents; classifying documents; finding names, dates, etc; intents and entities.
- **Computer Vision** - Satellite and drone image interpretation; face recognition; image captioning.
- Medicine - Finding anomalies in radiology images, including CT, MRI, and X-ray images.
- Image Generation - Colorizing images; increasing image resolution; removing noise from images; converting images to art in the style of famous artists
- **Recommendation Systems**, Web search - product recommendations; home page layout
- Playing games - Chess, Go, most Atari video games, and many real-time strategy games
- Other applications - **Tabular data**, forecasting, text to speech, and much more...

See more in <https://course.fast.ai/>

Deep Learning – Como?

Como foi possível?

- Alto poder computacional.
- Computação em Nuvem (*cloud*).
- Cálculos paralelizados.

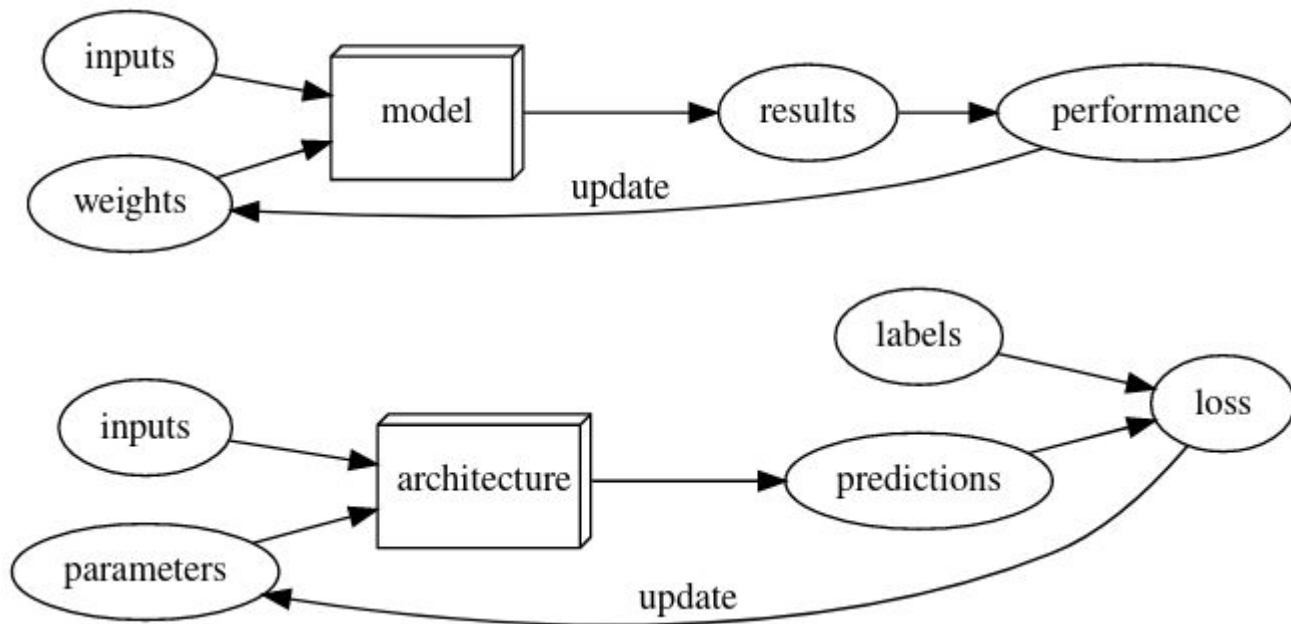


O que foi possível?

[Processamento Paralelo Utilizando GPU](#)

- Aumentar a arquitetura - várias camadas escondidas.
- Testar muitas arquiteturas diferentes - não precisa ser totalmente conectada, pode ter loops...
- Testar exaustivamente - técnicas de busca, Grid Search, Random Search.

Deep Learning – Nomenclatura



[Deep Learning for Coders with Fastai and Pytorch: AI Applications Without a PhD \(2020\)](#)

Um quadro quase completo de

Redes Neurais

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org

- Célula de entrada
- Célula de entrada retroalimentada
- Célula de entrada com ruído
- Célula escondida
- Célula escondida probabilística
- Célula escondida com disparo
- Célula cápsula
- Célula de saída
- Célula de saída igual à de entrada
- Célula recorrente
- Célula de memória
- Célula de memória com portão
- Kernel
- Convolução ou pool

Perceptron (P)



Feed Forward (FF)



Radial Basis Network (RBF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)




Denoising AE (DAE)



Sparse AE (SAE)




Deep Convolutional Network (DCN)




Deconvolutional Network (DN)



Deep Convolutional Inverse Graphics Network (DCIGN)



Generative Adversarial Network (GAN)



Liquid State Machine (LSM)



Extreme Learning Machine (ELM)




Echo State Network (ESN)




Auto Encoder (AE)




Variational AE (VAE)




Denoising AE (DAE)




Sparse AE (SAE)




Deep Residual Network (DRN)



Differentiable Neural Computer (DNC)



Neural Turing Machine (NTM)



Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)




Restricted BM (RBM)



Deep Belief Network (DBN)




Capsule Network (CN)



Kohonen Network (KN)




Attention Network (AN)




[Os tipos de redes neurais – IA Expert Academy](#)

Deep Learning – Deep Feed Forward (DFF)


Perceptron (P)



Feed Forward (FF)




Deep Feed Forward (DFF)




- O tipo mais básico, no qual a informação de entrada flui em sequência linear até os neurônios de saída.
- Cada neurônio é uma operação linear do tipo $Wx + b$, onde W e b são os parâmetros peso e bias do neurônio.
- Capazes de modelar vários problemas onde os dados de entrada têm um impacto atemporal nos dados de saída.

Deep Learning – Recurrent Neural Net. (RNN)

Recurrent Neural Network (RNN)



Long / Short Term Memory (LSTM)




- Recebem o resultado da operação matemática que eles mesmos realizaram no período temporal anterior.
- Modelam problemas com características temporais, por exemplo a previsão do tempo dado o histórico climático.
- LSTM estende a memória da RNN; são capazes de compor textos com coerência semântica e gramatical.


Extra - [Understanding LSTM Networks](#)

Deep Learning – AutoEncoder (AE)

Auto Encoder (AE)



Sparse AE (SAE)




- Os auto encoders são projetados para representar a informação de entrada em um espaço dimensional intrínseco.
- A camada de saída é uma cópia da informação de entrada, de forma que, durante o treinamento, os autoencoders (camadas escondidas) aprendem a representar a informação original em menos espaço, mas com informação suficiente para reconstruir os dados originais.

[Os tipos de redes neurais – IA Expert Academy](#)

Deep Learning – Convolutional Net. (DCN)















Deep Convolutional Network (DCN)



[Os tipos de redes neurais – IA Expert Academy](#)

- Nas camadas de convolução, a informação passa por vários filtros com a função de acentuar padrões regulares locais.
- Então, passam por uma estrutura de DFF clássica para a tarefa de classificação.
- Utilizada na classificação de imagens; os filtros acentuam atributos dos objetos necessários à sua correta classificação.
- *“Se inverter, você produz uma imagem.”*

Deep Learning – Crie sua Própria

| | |
|-----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
|  Input Cell |  Output Cell |
|  Backfed Input Cell |  Match Input Output Cell |
|  Noisy Input Cell |  Recurrent Cell |
|  Hidden Cell |  Memory Cell |
|  Probablistic Hidden Cell |  Gated Memory Cell |
|  Spiking Hidden Cell |  Kernel |
|  Capsule Cell |  Convolution or Pool |

[Os tipos de redes neurais – IA Expert Academy](#)

- Basicamente, pesquisadores estudam / desenvolvem novos tipos de neurônios.
 - Cada qual com sua característica própria / função única.
- Cria conexões entre eles, *i.e.*, camadas.
- Realiza uma busca extensiva sobre diversas arquiteturas até atingir o seu objetivo.
- *Ou, utilizam redes prontas.*

Deep Learning – Tecnologias



[PyTorch - Learning with Examples](#)



[TensorFlow - Basic image classification](#)



[FastAI - Practical Deep Learning for Coders](#)



[Keras - Basic image classification](#)

Deep Learning – Experimento



Deep Learning - Fast AI (pt-br)

Python notebook using data from [bosh-chewie](#) · 22 views · 5d ago · gpu, deep learning, classification, +1 more Edit tags

Deep Learning - Fast AI

Este notebook apresenta um conjunto de demonstrações de Deep Learning utilizando o pacote `fastai`, pacote construído em cima do `pytorch`. O pacote `fast ai` é utilizado em cursos, pesquisas e no mercado.

<https://www.kaggle.com/leomauro/deep-learning-fast-ai-pt-br>

Redes Neurais – Notas


Machine Learning clássica

- Interpretabilidade é fundamental;
- Quantidades menores de dados relativamente simples;
- *Feature engineer* simples;
- Treinamento em CPUs;
- Necessidade de prototipagem e operacionalização mais rápidas;
- A precisão dos resultados do conjunto de dados de teste é aceitável.

Deep Learning

- Interpretabilidade inviável;
- Grandes quantidades de dados rotulados com precisão (alta qualidade);
- *Feature engineer* complexa;
 - Transformações do conjunto de dados inicial serão necessários.
- Recursos de computação poderosos disponíveis (aceleração de GPU);
- Uma precisão muito alta é uma prioridade.

Dúvidas ???



fonte desconhecida

Muito obrigado pela
sua participação!!